植生調査資料の多変量解析の基礎とRでの実行方法

松村俊和
甲南女子大学人間科学部
欄外見出し：Rによる植生解析

■はじめに

植生学では調査資料を解析して，植物群集の特徴や環境との対応などを明らかにする．調査資料は多くの種数および地点からなるため，そままでは全体を見渡すことが難しい．植物社会学的表操作で得られた組成表や常在度表では，全体の組成を見渡すことができる．また，多変量解析を用いると情報を集約して示すことができる．

本稿では多変量解析の基礎的な手法の考え方とあわせて，Rで実行する方法を解説する．各手法の定義や計算方法の詳細は，小林 (1995) や伊藤 (2003) および個別の論文を参照してほしい．また，土居・岡村 (2011)，Wildi (2013)，佐々木ほか (2015) も参考になる．なお，本稿は 2025 年に実施した植生学会トレーニングスクールのRを活用した解析編の内容をもとしたものである．また，クラスター分析，序列化，Indicator Species Analysis は，https://matutosi.shinyapps.io/ecanvis/ でも実行可能である．

■準備

Rで分析を実行するときには，Rのインストールが必須である．本稿の執筆時の実行環境は Appendix 1 のとおりである．

本稿のコードを利用するには関連パッケージのインストールが必要である (Appendix 2)．tidyverse(Wickham et al., 2019) はコードを明快にするためのもので，Rでのコード全般で役立つ．vegan(Oksanen et al., 2025) は植生解析の定番である．ecan(Matsumura, 2023) は，クラスター分析や序列化は手法を簡単にするためのパッケージで，vegan を含む複数のパッケージの関数を統一的に扱うことができる．ggdendro(de Vries & Ripley, 2024) や ggrepel(Slowikowski, 2024) な

どは図示で使用する．

使用前には事前にパッケージを呼び出す(Appendix 3). `library()`で呼び出せばパッケージ名を明示しなくてもコードは動作する．ただし，Appendixのコードでは`dplyr::select()`のように「パッケージ名:: 関数名」と明示している．こうすることで，独自の関数やパッケージ内でパッケージを呼び出さなくても個別のコードが実行可能になる．コードは連続して実行することを想定しており，個別のコードで未定義の変数や関数は，それ以前の部分で定義済である．

■調査資料の取り扱い

Tidy data

パソコンへの調査資料の入力で重要なことは，tidyな形式にすることである．植生調査表の形式は，人間には理解しやすくても，パソコンには理解しづらいためだ．

Tidy data(Wickham 2014)とは整然とした状態にあるデータで，パソコンが理解しやすい状態に整理されていることを意味する．その条件は4つある．1つの変数が1つの列を，1つの観測が1つの行を，1つのタイプの観測群が1つの表を，1つの値が1つのセルを構成している必要がある．

Excelなどのスプレッドシートに地点情報を入力することを考える．1つの変数が1つの列とは，A列に地点名を，B列に調査日をそれぞれ入力した状態である．1つの観測が1つの行とは，2行目に1地点目の観測値である地点名，調査日，緯度，経度などを入力した状態である．1つのタイプの観測群が1つの表とは，地点情報と組成の情報を別々のシートに入力した状態である．さらに，1つの値が1つのセルとは，A2のセルには1つの値を入力した状態である．調査資料を入力するときには，これらの条件を満たすようにする．

Tidy dataの逆はmessy dataである．たとえば，tidyrパッケージのtable2というデータはmessy dataの例である(Appendix 4). これは結核症例数を示したもので，type列にcases(罹患数)とpopulation(人口)という2つの項目があり，その数値がcount列にある．しかし本来は，casesとpopulationは項目名として，それぞれが別の列に配置されるべきである(Appendix 5).

パソコンへの入力と出力

調査資料のパソコンへの入力では，Excel等のスプレッドシートを使うのが簡易である．tidyな形式で出力する以外に注意点が3つある．1つ目はシートの1行目には項目名を入力することで，2つ目は空の行，空の列，空のセルはつくらないことである．見やすさを考慮して1行目や1列目を空ける必要はない．また，欠損値は空のセルにはせず，"NA"あるいは"-"のような文字列を入力する．空のセルだと欠損値か入力漏れか後で判別できないためである．欠損値の文字列は任意だが，調査資料に含まれないものを使う．3つ目は，ファイルとして出力するときはCSV(Comma Separated Values，カンマ区切りのテキストファイル)あるいはTSV(Tab Separated Values，タブ区切りのテキストファイル)を使うことである．CSVやTSV形式のデータは，読み込み時に誤変換が起こりにくい．ファイルの文字コードは，UTF-8が一般的である．CSVやTSVはOSによらず読み込み可能であり，再利用が容易だ．スプレッドシートでの出力には，セルの書式を文字列に設定すると誤変換しにくい．

R でのデータの読み込みと出力

CSV は readr の`read_csv()`で，TSV は`read_tsv()`で，Excel 形式は openxlsx の`read.xlsx()`で読み込みできる (Appendix 6)．引数として各列のデータの種類や読み込みを省略する行を指定できる．Excel形式でシート名が複数あるときは，引数`sheet`でシート番号かシート名を指定する．また，Excel形式で複数のシートがあるときは，松村 (2025) に掲載の関数`read_all_sheets()`を使うと全シートのデータを読み込むことができる．

なお，出力するときは，CSVではreadrの`write_csv()`を，TSVでは`write_tsv()`を，Excel形式ではopenxlsxの`write.xlsx()`を使うことができる．

R でのデータの結合

植生調査資料は，地点，組成，種に関するデータで構成することが一般的である．それぞれをtidyな形式にしてから結合する．

ここでは vegan に含まれるデータを使用する．vegan は地点データの

dune.env と組成データの dune を含んでいる．dune.env は，行ラベルである地点名を列名に変換する (Appendix 7)．dune は，組成表の行と列を入れ替えた形式であり tidy な形式ではない．そのため，ecan の`table2df()`を使って tidy な形式に変換する (Appendix 8)．引数`st`，`sp`，`ab`には，地点，種，出現量のデータの列名として使用する文字列を指定する．vegan には種のデータがないため，架空の種データを生成する (Appendix 9)．ここでは，種名の 1 文字目と 6 文字目を名義尺度の種データとする．

データを結合するには，dplyr の`left_join()`を使い，組成と地点は地点名で，種データとは種名で結合する (Appendix 10)．

データの種類と変換

植生学では記録するデータのうち，出現量は植被率や個体数あるいは有無などがある．植被率には，Braun-Blanquet の優占度の階級値や百分率などがある．記録した値を必要に応じて変換することもある (表 1，Appendix 11)．たとえば，Braun-Blanquet の階級値を，各階級の中央値などに変換することがある．また，百分率を平方根変換や有無に変換してばらつきを小さくすることがある．

表 1

単純なデータ変換ではなく，地点内の相対値である相対優占度を求めることがある．地点 j での種 i の出現量を n_{ij}，地点 j の全種の出現量の合計を N_j とすると，相対優占度 P_{ij} は，n_{ij}/N_j である (Appendix 12)．相対値に変換することで，地点間の出現量のばらつきを除外できる．さらに，相対優占度を平方根変換することを，Hellinger 変換といい，地点内のばらつきを小さくする．

■種多様性指数

種多様性指数は，生物群集の豊かさを数値化したもので，種数だけでなく均等度を考慮した指数がある．種数は空間規模が大きくなるほど豊かになるため，比較には空間規模の統一が必要である．

地点内の多様性を α 多様性，地点間の多様性を β 多様性，地域内の多様性を γ 多様性という．α 多様性と γ 多様性の空間規模は任意である．α 多様性では，森林ならば 100-400m^2 などの空間規模，草原ならば 1-10m^2 が多い．γ 多

様性の空間規模は幅が広く，複数個の調査地点，景観規模，市町村単位，都道府県単位などが使われる．β多様性は地点間の多様性であり，γ多様性とα多様性との比率と定義するときと，γ多様性とα多様性との差として定義することがある．

α多様性

α多様性の代表的な指数として，種数，Simpsonの均等度指数，Shannonの情報量指数がある．α多様性の種数は基本的な情報として重要である．種数と均等度の両方を考慮した種多様性指数は，最小値が1で，最大値が出現種数と同じになるため，Simpsonの指数1/dが理解しやすい．

Simpsonの指数は，本来は集中度指数としてdがある．集中度と均等度は反対の概念で，その逆数である1/d, 1との差である1-dが均等度指数として使われる．Simpsonの均等度指数を求めるには，まず相対優占度を計算する．各出現種の相対優占度を二乗して合計したものがSimpsonの集中度指数dである．1つの種に優占度が集中したとき，つまり出現種が1種のときに最大値の1になる．集中度が低い，つまり多くの種が出現するときや出現種の優占度が均等であるときにdは小さくなる．全ての種が均等に出現するときには，dは種数の逆数と等しくなる．

1 / dは，出現種が1種のときに最小値の1に，全出現種の優占度が均等なときには種数と同じになる．1 - dは，最小値が0で，出現種の優占度が均等であるほど大きくなる．

たとえば，1地点に5種の植物が出現するとして，均等度が異なる場合を考える全種の出現量が均等で20とすると，dが0.2, 1-dが0.8, 1/dが種数と同じ5である(Appendix 13). 一方，ある種が60で残りの4種が10のように1種だけで半分以上を占めているとき，dが0.4, 1-dが0.6で，1/dが2.5である．

Shannonの情報量指数は，各種の相対優占度に相対優占度の対数を乗じたものを合計して，符号を逆転させたものである(Appendix 14). 対数の底はe, つまり自然対数を使うことが多いが，底に2を使うこともある．他の研究と比較するときには，対数の底を確認しなければならない．

R でのα多様性の計算

R の ecan で種数，Shannon の指数，Simpson の指数 (1-d と 1/d) を計算するには，関数`shdi()`を使う (Appendix 15)．第 1 引数にはデータフレームを指定する．第 2 引数から第 4 引数には，地点名，種名，出現量の列名を文字列で指定する．第 2 引数以降を省略すると，データフレームの 1 列目が地点名，2 列が種名，3 列名が出現量として扱われる．

地点の属性別でのα多様性の平均値を求めるには，地点データを結合した後で，`group_by()`でグループ化し，`summarise_if()`で数値の列の平均値を計算する (Appendix 16).

全体の様子を確認するためには，箱ひげ図が利用できる．箱ひげ図とあわせてあわせて地点ごとのデータを図示すると個々のデータを合わせて確認できる (図 1，Appendix 17)．`ggplot()`で x 軸に`Management`を，y 軸に`i`(1/d) を指定する．`geom_jitter()`による個別の点の表示との重複を避けるため，箱ひげ図を描画する`geom_boxplot()`の引数で`outlier.shape = NA`を指定している．

図 1

図を論文で使うときには全体のテーマや軸ラベルなどを変更する必要がある．ggplot2 の詳細は https://ggplot2-book.org/ (2025,12 参照) を，日本語フォントでの文字化け対策は松村 (2025) が参考になる．

β多様性とγ多様性

γ多様性の空間規模は，α多様性を計算した地点の複数の集まりのこともあれば，もっと大きな空間規模のこともある．さらに，入れ子状に考えることがでる (Wagner et al. 2000)．具体的には，地点の複数の集まり，この集まりである景観規模，景観規模の集まりの市町村，市町村の集まりのの都道府県などである．

β多様性は，γ多様性とα多様性の比もしくは差として定義される．多くの場合で比を用いているが，差を用いている場合がある．そのため，β多様性を比較する際には，それぞれの定義を確認する必要がある．

■クラスター分析

クラスター分析は，地点あるいは種について，その出現の仕方に基づいて分類する手法である．植生学では地点を分類することが多く，地点間の類似度を計算して地点を結合する．類似度と結合方法には多くの手法があり，手法によって得られるクラスターが異なる．

基本的な考え方

ここでは，a からj までの label および一様分布の乱数 x と y からなる架空のデータ (Appendix 18) を考える．xy 座標に散布図を描くと，それぞれの位置関係がわかる (図 2，Appendix 19). 図 2

ユークリッド距離を計算すると，最小の距離は b-h 間の 0.132 であり，近い順でに e-h 間の 0.211，b-j 間の 0.224 と続く (Appendix 20). 最近隣法は最も近いものから順に結合する．まず，最も距離の近い b と h を結合する．2 番目に近いのは e と h であるため，e を結合済の bh と結合する．3 番目に距離の近いのは b と j であるため，ebh と j を結合する．

R では，stat の`hclust()`でクラスター分析が実行可能で，ggdendro の`ggdendrogram()`で樹状図を描画できる (図 3 左，Appendix 21). 図 3 左の最近隣法のクラスターを 2 つに分割すると，g だけのクラスターとそれ以外のクラスターになる．このとき，クラスター内の並び順に意味はない．つまり，g と f は隣り合っており g と i は離れた位置にあるが，g-f 間と g-i 間の距離とは無関係である． 図 3

距離と類似度

クラスター分析で使用する距離は類似度の逆の概念である．植生調査資料の地点間あるいは種間の距離は，出現量や種の有無をもとに計算する． 図 4

距離にはユークリッド距離，Hellinger 距離，マンハッタン距離，Bray-Curtis 距離などがある．ユークリッド距離は，点間の直線距離である (図 4, Appendix 22). Hellinger 距離は，相対優占度を平方根変換する，つまり Hellinger 変換した値でユークリッド距離を計算したものである．マンハッタン距離は，碁盤の

目の移動距離である．Bray-Curtis 距離は，マンハッタン距離を標準化したものである．標準化とは，標本サイズの影響を除外するために出現量で割ることである．

上記の距離のうち，ユークリッド距離，Hellinger 距離，マンハッタン距離はメトリックであり，Bray-Curtis 距離は半メトリックである．メトリックな距離とそうでない距離では，クラスター分析の結合方法や序列化で使える手法が異なる. メトリックであるためには，非負性，同一律，対称性，三角不等式の 4 つの条件を満たす必要がある．非負性とは距離は必ず 0 以上であること，同一律とは全く同じ点間の距離は 0 であること，対称性とは距離 ab と距離 ba は等しいことである．三角不等式とは a から b への距離が任意の第 3 の点 c を経由した距離の和より小さいか等しいことで，遠回りをする方が近道よりも短くならないことである．Bray-Curtis 距離は，三角不等式を満たさないことがあるため，半メトリックな指標とされる．

結合方法

クラスター分析における主な結合方法として，最近隣法，非加重群平均法，Ward 法などがある．同じ距離に基づくものであっても，結合方法によって形成されるクラスターは異なる (図 3，Appendix 23).

先述の最近隣法は一度だけ距離を計算すれば良いため，計算量が少ないという利点がある．ただし，グループが鎖状あるいは帯状に細長くつながりやすいという欠点がり，植生学の分析で用いられることはほとんどない．

非加重群平均法は，グループ結合後にグループ間の距離を再計算する．再計算時には，クラスターに属する全ての要素間の距離の算術平均を計算する．計算量は多くなるものの，よほど多くの地点でない限り問題になることはない．非荷重群平均法で用いる距離は，メトリックな指標でなくても構わない．

Ward 法はクラスター内での分散が小さくなるようにグループを結合する．分類感度がよく，外れ値の影響を受けにくいとされる．Ward 法で用いる距離は，メトリックな指標のみである．

R でのクラスター分析

距離と結合方法の組み合わせは多くあるものの，植生学をはじめとする生態学でよく使われる組み合わせには2つである．1つ目は，Bray-Curtis 距離と非荷重群平均法の組み合わせである．Bray-Curtis 距離はマンハッタン距離の標準化であるため，生態学的な意味が理解しやすいのが利点である．ただし，半メトリックでありWard 法が使えないため非荷重群平均法が使われる．2つ目は，Hellinger 距離と Ward 法の組み合わせである．Hellinger 距離はメトリックであるため，Ward 法が使用可能である．

クラスター分析は ecan の関数`cluster()`で実行可能である．`cluster()`の引数には，この組成表を転置した形式で渡すため，事前に`df2table()`で変換する．結合方法として`c_method = "average"`で非荷重群平均法を，距離を`d_method = "bray"`で Bray-Curtis 距離を指定する (Appendix 24)．なお，Ward 法は`d_method = "ward.D2"`と，Hellinger 距離は`d_method = "hellinger"`と指定する．

クラスター分析の結果を表示するには，`cluster()`の結果を代入したオブジェクトを表示する．詳細な情報を得るには，関数`str()`を使う．`str()`は struscure の省略で，オブジェクトの構造を出力するため，データの構造と概略がわかる (Appendix 25).

クラスター分析の結果は，単に`plot()`で図示できる．ただし，ここでは ggdendro の`ggdendrogram()`を使う (Appendix 26).

ここでは，よりわかりやすくするために地点名にグループ名を追加して表示させる．第1引数にクラスター分析の結果を，第2引数に分析前の地点データを，第3引数に個別の地点名を示す列名を，第4引数にグルー名を示す列名を指定する．`ggdendrogram()`で図示すると，地点名の前にグループ名が表示される (図 5, Appendix 27).

図 5

さらに見やすくするために，グループ別で着色するときは，ecan の`cls_color()`を使う．グループ名を追加したオブジェクト`cls_group`を`as.dendrogram()`で樹状図の形式に変換しておく．1つ目の`plot()`でプロットし，その後に dendextend(Galili, 2015) の`colored_bars()`で着色し，さらに2つ目の`plot()`で地点名を上書きする (Appendix 28).

■序列化

序列化は，地点や種の出現の仕方に基づき次元軸上に位置づける分析手法である．主な手法として PCA(Principal Component Analysis), CA(Correspondence Analysis), DCA(Detrended Component Analysis), PCoA(Principal Coordinate Analysis), nMDS(non-metric Multidimensional Scaling) などがある．また，環境傾度との対応関係を明らかにする手法として CCA(Canonical Correspondence Analysis) と RDA(Redundancy Analysis) がある．

クラスター分析と同様に，距離との組み合わせで結果が異なる．また，手法によっては使える距離に制限がある．

PCA：主成分分析

PCA は，多変量のデータの次元を削減する手法の1つである．たとえば，植生調査資料に全体で100種が出現したとすると，種数と同じ100次元の空間が考えられる．そもそも，100次元のデータを理解することは困難であり，重要な成分である主成分を見つけるのがPCAである．

ここでは，x と y の2変数のデータがあるとする．この配置を説明するのに最も良い軸は x 軸でも y 軸でもない．左下から右上へ引いた実線が x と y の両方を説明をする最適な軸である (図 6, Appendix 29). PCA ではこれを第1軸という．

図 6

第1軸と直行する軸が第2軸で，第1軸の次に説明の程度の大きい軸である．2変数のときは，2つの軸で全てを説明可能であり，多変量の場合はその変数分の軸がある．ただし，実際には第1軸と第2軸など少数の軸で多くを説明できる．説明量を寄与率といい，この例では第1軸の寄与率が0.919, 第2軸が0.081であり，9割以上を第1軸で説明可能であることを示している．

馬蹄効果

馬蹄効果とは，種の入れ替わりのある長い環境傾度のデータを序列化の結果を配置したときに，馬蹄形になってしまうことである．種の入れ替わりが一定のデータがあったときに，直線上に配置されるとするのが，人間の考え

方である．

たとえば，10地点14種からなるデータを考える(Appendix 30)．地点1から地点10があり，隣接した地点の類似度はそれれぞれ同じである．そのため，地点1から地点10が一定間隔で環境傾度上に並ぶことを想定できる．しかし，PCAの結果を描画すると馬蹄形が現れる(図7，Appendix 31)．つまり，環境傾度では遠いと考えられる地点が近くに配置される．出現種のない地点が多いとき，つまり類似度が0のデータが多いときに馬蹄形が現れやすい．長い環境傾度を扱うことのある植生調査資料では，このようなことはよく起こる． 図7

DCA：除歪対応分析

主に比例尺度や間隔尺度などの量的データの分散を分析して次元を削減するPCAに類似しているが，名義尺度の度数表を扱う次元削減手法としてCA(対応分析)がある．CAはカイ二乗距離を基準にして行と列のカテゴリ間の関連性を分析する．このCAの結果にも馬蹄効果が現れることがあり，DCAはCAの馬蹄効果を強制的に除去する手法である．

CAの第1軸で出現した馬蹄効果を除去するために，DCAでは第1軸を任意の区間で区切る．各区間での第2軸の平均値を求めて，各区間の平均が等しくなるように第2軸の数値を計算する．

区間の区切り方は任意であり，区切り方で結果が異なる．つまり，かなり恣意的な再配置なため多くの批判があり，現在ではあまり用いられない．ただし，DCAだけでは使わなくても，後述のCCAやRDAでの環境傾度の幅の広さを求めるときに，DCAの第1軸が利用可能である．

PCoA：主座標分析

PCoAは，次元削減の目的はPCAと同じである．PCAはデータの分散を最大化する主成分を見つける．一方，PCoAでは元の距離をできるだけ保持しながら低次元空間に変換する．

入力できる距離は，PCAでは距離がメトリックでなければならない．一方，PCoAでは任意の距離が使用可能である．つまりメトリックでないBray-Curtis距離が距離として使える．なお，PCoAでユークリッド距離を使うとPCAと

同じ結果になる．

nMDS：非計量多次元尺度法

nMDSは，PCoAと同様に任意の距離が使用可能である．PCoAとは違い，距離そのものではなく距離の順序を使う．つまり，比率尺度ではなく順序尺度を使う．

nMDSでは反復計算をするため，毎回同じ結果になるとは限らない．場合によっては局所解に陥る可能性があり，正しい結果が得られない可能性がある．また，軸の向きに意味がない点も注意が必要である．なお，Rでは`set.seed()`で乱数種を設定すれば，一定の結果を得ることができる．

反復計算でStress valueを計算し，Stress valueが0.05未満のときは非常に良い，0.1未満で良い，0.2未満で許容範囲と評価されることが多い．

CCA：正準相関分析とRDA：冗長性分析

CCAとRDAは環境要因などの説明変数を用いて，種の組成や地点の類似性などの応答変数の変動を分析および可視化できる．CCAはCAの環境要因対応版である．CCAは任意の距離を使用することができ，環境変数の幅が長いときに使われる．RDAはPCAの環境要因対応版で，メトリックな距離のみを使うことができ，環境変数の幅が短いときに使う．

β多様性が高い，つまり環境傾度の幅が広いときにCCAを，β多様性が低い，つまり環境傾度の幅が狭いときにはRDAを使う．具体的には，DCAの第1軸の長さが第1軸の長さ(標準偏差単位)が4を超えるときは，種の分布の山が大きくずれておりCCAが推奨される．一方，第1軸の長さが3を下回るときは，種の分布の山がほぼ重なっており，RDAが推奨される．3から4までのときは，PCAやCAの散布図を描画して，馬蹄効果が目立つときにはCCAを用い，目立たないときにはRDAを用いるのが良いとされる．

Rでの序列化

植生学をはじめとする生態学の分野では，Bray-Curtis距離をもとにしたPCoAあるいは，Bray-Curtis距離をもとにしたnMDSがよく用いられる．

序列化を実行するには，事前に組成表を転置した形式に変換し，ecan の関数ordination()を使う．o_method = "nmds"で序列化手法として nMDS を，d_method = "bray"で Bray-Curtis 距離を指定できる (Appendix 32)．ordination()は，指定した序列化手法で PCoA や nMDS を実行して，実行結果を整理して返す．なお，実際に分析するのは ecan ではなく，そこから呼び出した別のパッケージの関数である．

序列化の結果の一部を取り出すには ecan の関数ord_extract_score()を使う (Appendx 33)．ord_extract_score()で抽出したオブジェクトは単なるデータフレームであり，ggplot2 でプロットするのは容易である (図 8，Appendix 34)． 図 8

次に，種をグループで着色して散布図を描画する．ecan の関数ord_add_group()で序列化の結果にグループ名を追加する．第 1 引数に序列化の結果を，第 2 引数に種のデータを，第 3 引数に地点とグループ名の対応のあるもとのデータフレームを，第 4 引数に個別の種名を示す列名を，第 5 引数にグループ名を示す列名をそれぞれ指定する (Appendix 35)．

ord_add_group()で得たオブジェクトはデータフレームなので，ggplot2 で簡単に図化できる．種名に丸で色付けするには，geom_point()を使う．ggplot2::geom_text()をgeom_point()の後に実行することで，丸印を先に描画してその上に種名を描画する (Appendix 36)

■Indicator Species Analysis：指標種分析

Indicator Species Analysis(Dufrêne & Legendre 1997) は，グループ別の地点に特徴的に出現する種を明らかにするものである．出現の有無と出現量のどちらも使用可能である．無作為化検定 (permutation test) によって統計的な有意性を計算できる．なお，無作為化検定とはランダムに並べ替えることを繰り返して，統計量の分布を求めるノンパラメトリック検定である．

指標値の計算

種 i のグループ j での指標値を計算するとする．種 i のグループ j での出現量を種 i の全体での出現量で割る．これはグループ j での出現量が高いほど大きな値になる．また，種 i のグループ j での出現回数を種 i の全体での出現回数で

割る．これはグループjでの出現頻度が高いほど大きな値になる．つまり，グループjでの出現量や出現頻度が高いほど指標値は大きな値になる．

R での Indicator Species Analysis

Indicator Species Analysis には ecan の関数`ind_val()`を使う．引数に`row_data = TRUE`を指定すると labdsv の関数`indval()`をそのまま返す (Appendix 37). このときの返り値の詳細は，`indval()`のヘルプを参照してほしい．

論文や図示で使うには，`indval()`から得た情報から必要なものを抽出する．その場合には，既定値 (`row_data = FALSE`) のまま実行する (Appendix 38). `ind_val()`は，グループ名，種名，指標値，p 値からなるデータフレームを返す．

Indicator Species Analysis の結果を図化するには，x 軸にグループ名を，y 軸に指標値を，p 値を点と文字列の大きさにして，種名をプロットする (図 9, Appendix 39).

図 9

■引用文献

de Vries, A. & Ripley, B. D. 2024. ggdendro: Create Dendrograms and Tree Diagrams Using 'ggplot2'. R package version 0.2.0.

土居秀幸・岡村　寛 2011. 生物群集解析のための類似度とその応用: R を使った類似度の算出, グラフ化, 検定. 日本生態学会誌, **61**: 3–20.

Dufrêne, M. & Legendre, P. 1997. Species assemblages and indicator species: the need for a flexible asymmetrical approach. Ecological Monographs, **67**: 345–366.

Galili, T. 2015. dendextend: an R package for visualizing, adjusting, and comparing trees of hierarchical clustering. Bioinformatics.

伊藤秀三編 2003. 朝倉書店，東京.

小林四郎 1995. 生物群集の多変量解析. 蒼樹書房，東京.

Matsumura, T. 2023. ecan: Ecological Analysis and Visualization. R package version 0.2.1.

松村俊和 2025. R による自動化・効率化レシピ集. 森北出版，東京.

Oksanen, J., Simpson, G. L., Blanchet, F. G., Kindt, R., Legendre, P., Minchin, P. R.,

O'Hara, R., Solymos, P., Stevens, M. H. H., Szoecs, E., Wagner, H., Barbour, M., Bedward, M., Bolker, B., Borcard, D., Borman, T., Carvalho, G., Chirico, M., De Caceres, M., Durand, S., Evangelista, H. B. A., FitzJohn, R., Friendly, M., Furneaux, B., Hannigan, G., Hill, M. O., Lahti, L., Martino, C., McGlinn, D., Ouellette, M.-H., Ribeiro Cunha, E., Smith, T., Stier, A., Ter Braak, C. J. & Weedon, J. 2025. vegan: Community Ecology Package. R package version 2.7-2.

佐々木雄大・小山明日香・小柳知代・古川拓哉・内田　圭 2015. 生物群集の構造と多様性の解析. 共立出版, 東京.

Slowikowski, K. 2024. ggrepel: Automatically Position Non-Overlapping Text Labels with 'ggplot2'. R package version 0.9.6.

Wagner, H. H., Wildi, O. & Ewald, K. C. 2000. Additive partitioning of plant species diversity in an agricultural mosaic landscape. Landscape Ecology, **15**: 219–227.

Wickham, H. 2014. Tidy data. Journal of Statistical Software, **59**: 1–23.

Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., Franąois, R., Grolemund, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T. L., Miller, E., Bache, S. M., Müller, K., Ooms, J., Robinson, D., Seidel, D. P., Spinu, V., Takahashi, K., Vaughan, D., Wilke, C., Woo, K. & Yutani, H. 2019. Welcome to the tidyverse. Journal of Open Source Software, **4**: , No. 43 1686.

Wildi, O. 2013. Data Analysis in Vegetation Ecology. Wiley-Blackwell.

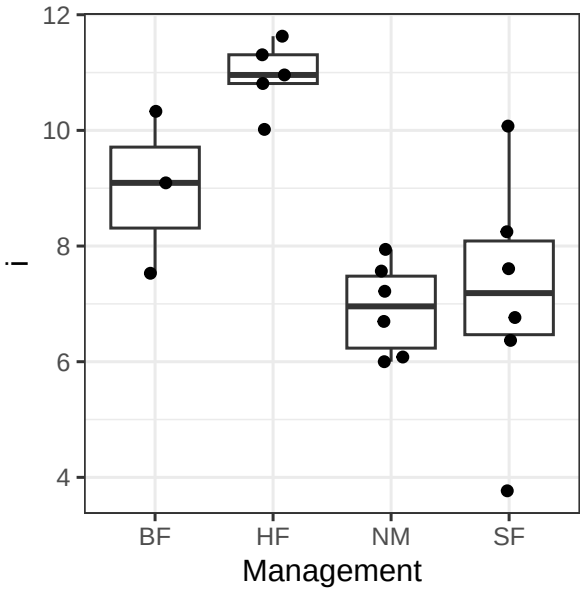

図 1. グループ別でのα多様性の図示

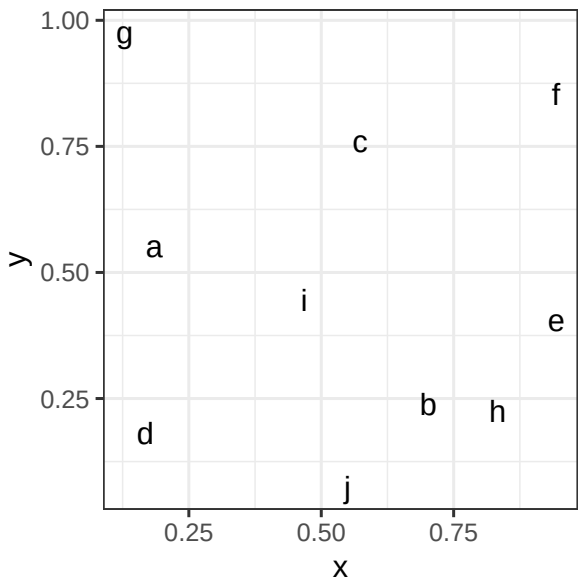

図 2. 架空データの配置

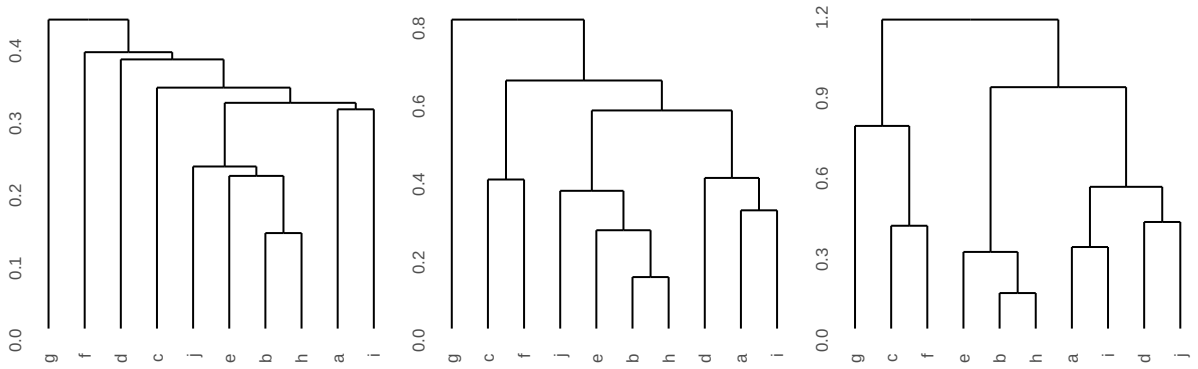

図 3. クラスター分析の結合方法の比較．左：最近隣法，中央：非荷重群平均法，右：Ward 法

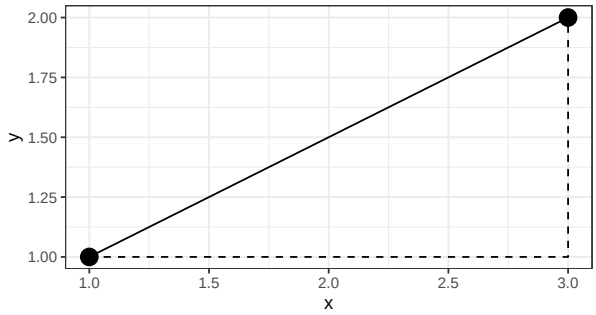

図 4. ユークリッド距離 (実線) とマンハッタン距離 (点線)

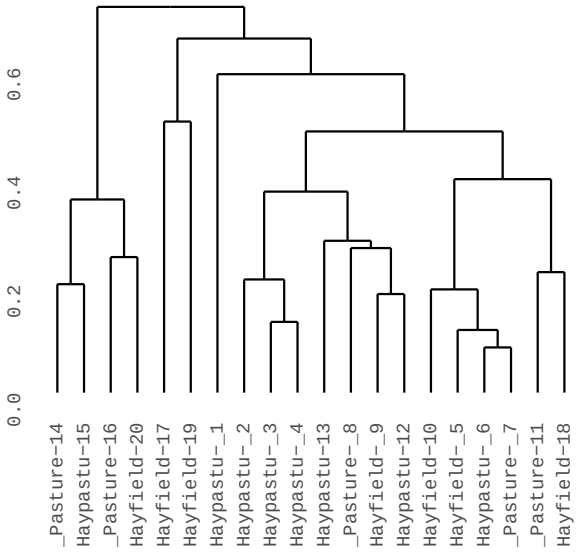

図 5. グループ名を追加した樹状図

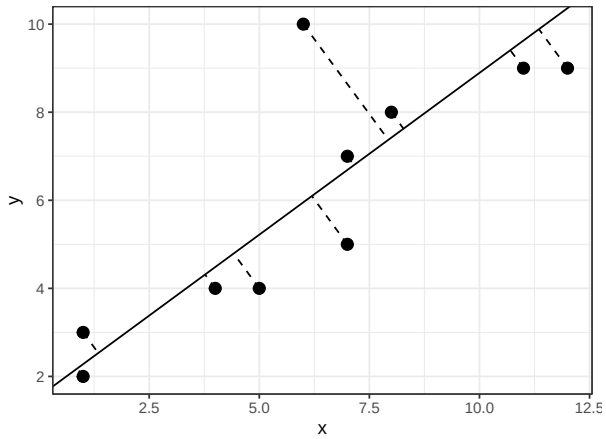

図 6. PCA の考え方

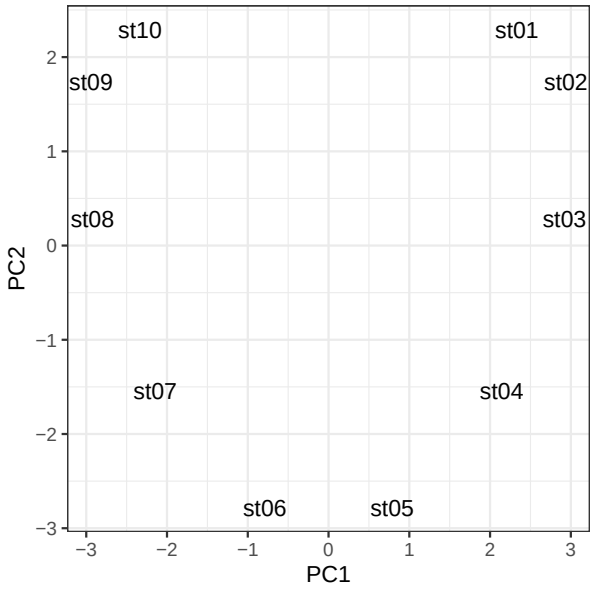
st10
st01
st09
st02
st08
st03
st07
st04
st06
st05
PC2
PC1
2
1
0
−1
−2
−3
−3
−2
−1
0
1
2
3

図 7. 馬蹄効果

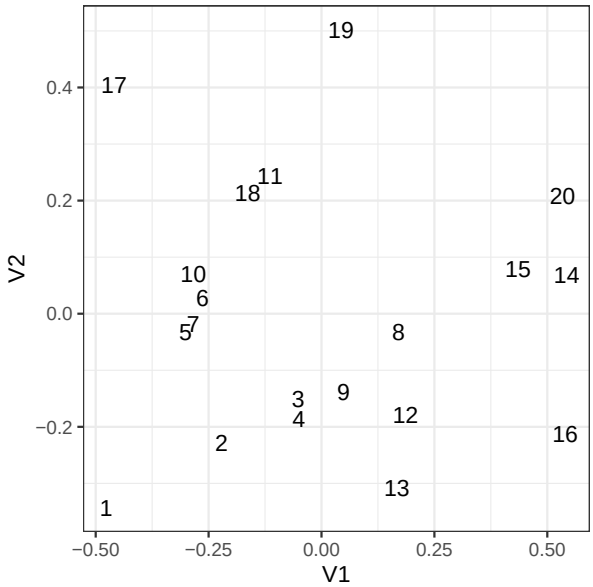

図 8. 序列化の結果の図示

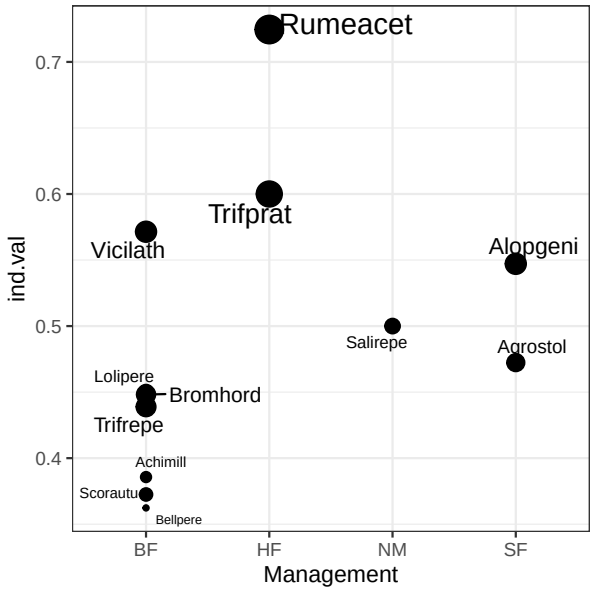

図 9. 指標種分析の結果の図示

表 1. データ変換の例

階級値	中央値	百分率	平方根変換
5	87.50	80.00	8.94
4	62.50	60.00	7.75
3	37.50	30.00	5.48
2	17.50	15.00	3.87
1	5.50	8.00	2.83
+	0.55	0.10	0.32
0	0.00	0.00	0.00